APRENDIZAJE DE MÁQUINA · ENTREGA FINAL

¿Se puede predecir la calidad de un vino tinto con su análisis de laboratorio?

Análisis exploratorio, clasificación y regresión con 1.359 vinos portugueses

Santiago Andres Saavedra Garcia · 2251936
Manuel Esteban Cardenas Hurtado · 2251663
Grupo B1 · 2026-2 · Universidad Industrial de Santander

EL PROBLEMA

El laboratorio es más rápido que la cata

Hoy la calidad de un vino la decide un panel de catadores. Es costoso, no se puede catar cada lote y dos catadores pueden dar notas distintas.

Las mediciones de laboratorio (alcohol, acidez, sulfatos y otras 8) son baratas y objetivas.

Dataset: Wine Quality, vino tinto *Vinho Verde* (Cortez et al., 2009, UCI).

Objetivo 1

Identificar los vinos de alta calidad, con puntaje de 7 o más.

Objetivo 2

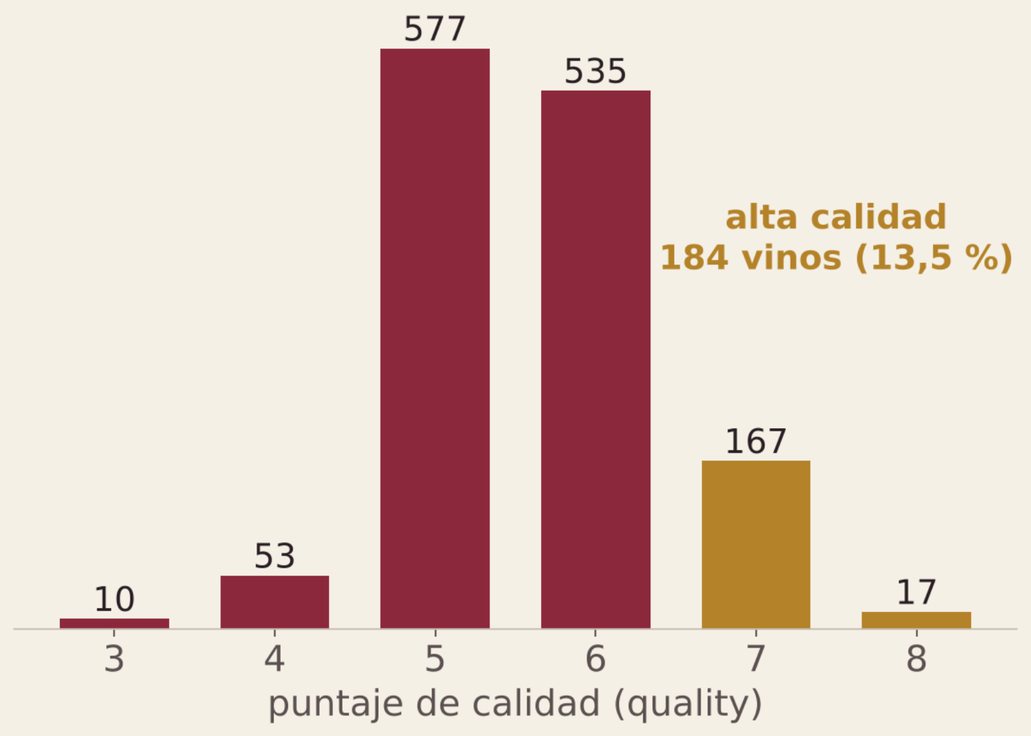
Saber qué propiedades del laboratorio pesan más en la calidad.

En esta entrega

Predecir además el puntaje exacto, como problema de regresión.

PARTE 1 · ANÁLISIS EXPLORATORIO

Pocos vinos son de alta calidad



1.359

vinos distintos, después de quitar 240 filas repetidas de las 1.599 originales

13,5 %

son de alta calidad: por cada vino bueno hay 6,4 normales

4

variables candidatas: alcohol, acidez volátil, sulfatos y ácido cítrico

PARTE 2 · CLASIFICACIÓN

¿Este vino es de alta calidad o no?

Cinco modelos supervisados compiten con las mismas reglas. Gana el que mejor encuentre los vinos buenos.

CÓMO MEDIMOS

La accuracy engaña: usamos F1

86,5 %

de accuracy saca un modelo que siempre dice «estándar»

F1 = 0

porque no encuentra ni un solo vino bueno

El F1 solo sale alto si el modelo encuentra los vinos buenos (recall) y además lo que marca como bueno lo es de verdad (precision).

1. Separar el test

20 % (272 vinos) al azar y estratificado. No se toca hasta el final.

2. Validación cruzada

El 80 % se divide en 5 partes que se turnan como examen.

3. Escalado en Pipeline

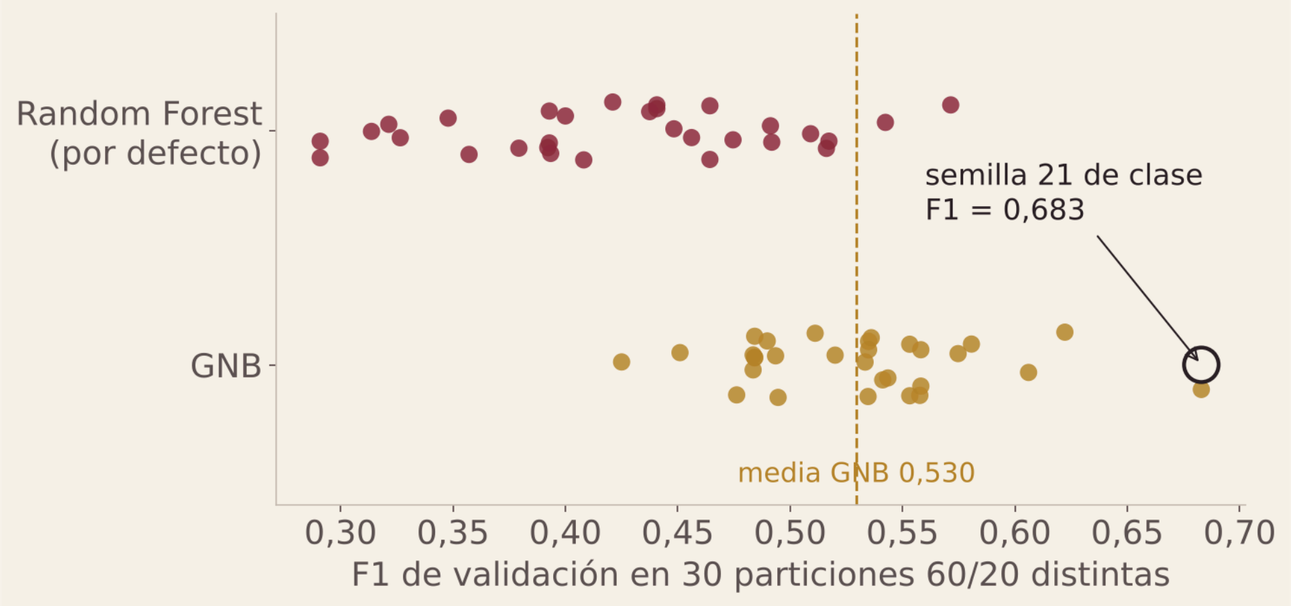
Se calcula solo con los vinos de estudio de cada ronda.

4. Test una vez

Solo el modelo ganador presenta el examen final.

POR QUÉ VALIDACIÓN CRUZADA

Una sola partición depende de la suerte



0,43 → 0,68

F1 del mismo modelo (GNB) en 30 particiones distintas

La partición de clase, semilla 21, fue la más favorable de las 30. Con ella habríamos creído que GNB era 0,15 mejor de lo que es.

LOS COMPETIDORES

Dos líneas base y cinco modelos

Trivial

Siempre dice «estándar». F1 = 0.

Regla de alcohol

Alta calidad si alcohol ≥ 11,6 %. F1 = 0,460.

Gaussian NB

Probabilidades por variable, como si fueran independientes.

Árbol de decisión

Preguntas de sí o no sobre las mediciones.

Random Forest

300 árboles distintos que promedian su opinión.

SVM (RBF)

Frontera curva con el margen más ancho posible.

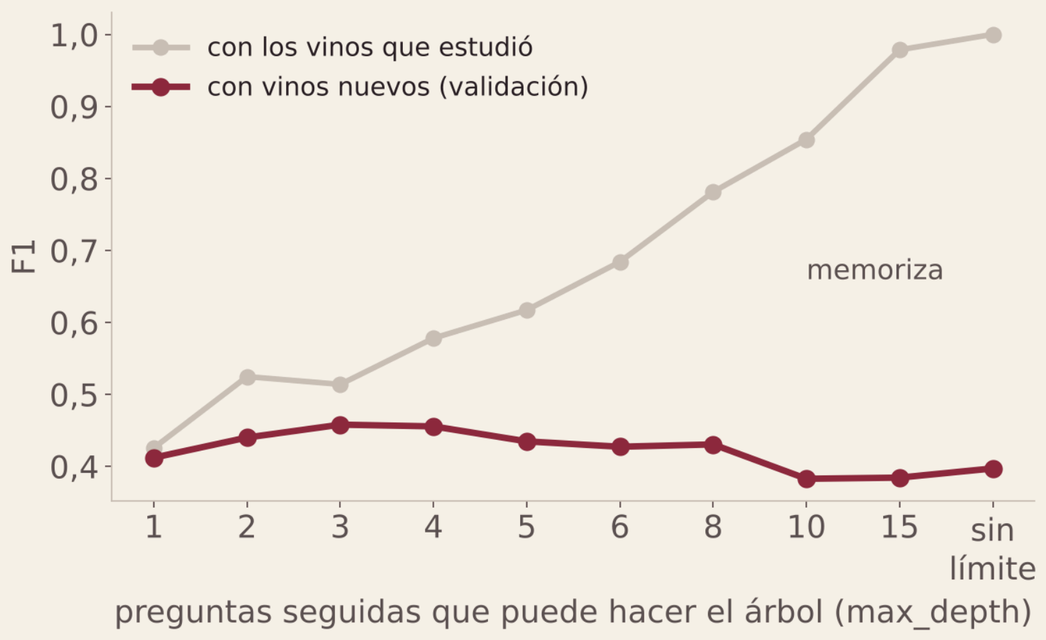
Gradient Boosting

Árboles pequeños en fila que corrigen errores.

Hiperparámetros elegidos con GridSearchCV optimizando F1. Árbol, Random Forest y SVM usan pesos de clase: un error con un vino bueno cuenta 6,4 veces más.

AJUSTE DE HIPERPARÁMETROS

Sin límites, los árboles memorizan



Random Forest sin ajustar

1,00 / 0,42

F1 con los vinos que estudió / con vinos nuevos

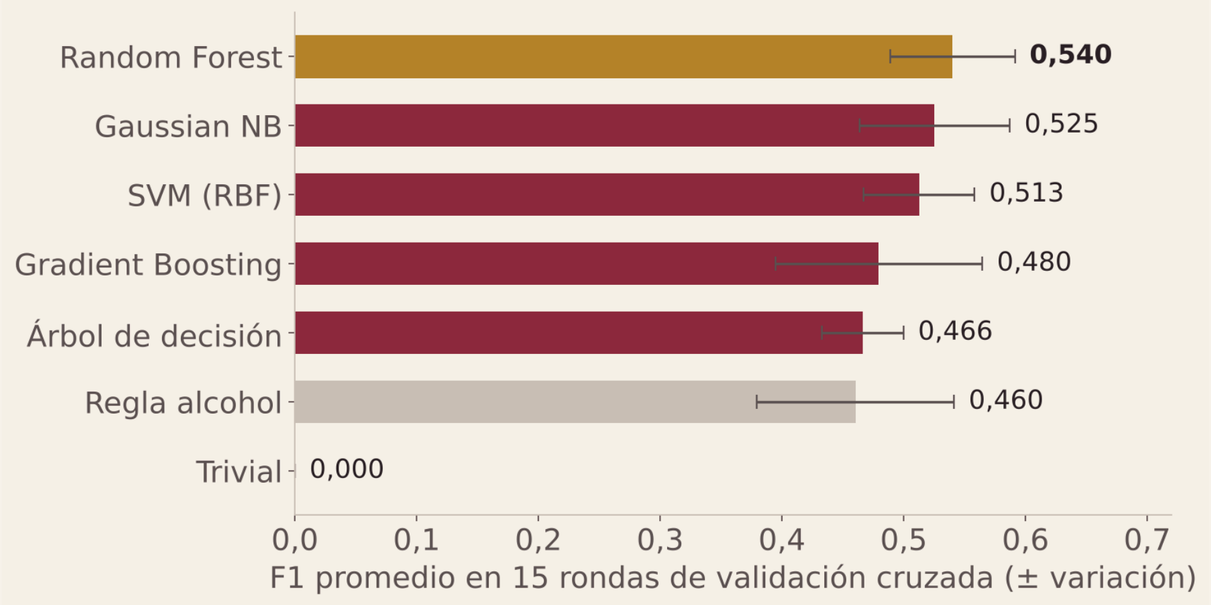
Ajustado (profundidad 8, mínimo 5 vinos por hoja)

0,80 / 0,54

la brecha se reduce: memoriza mucho menos

SELECCIÓN

Random Forest es el mejor clasificador



0,540 ± 0,051

F1 promedio en 15 rondas de validación cruzada (5 × 3)

Regla fijada antes de ver resultados: gana el mayor F1; si dos quedan a menos de 0,01, desempata el PR-AUC. RF le ganó a GNB por 0,015.

También fue el que mejor ordena los vinos: ROC-AUC 0,882 y PR-AUC 0,609.

EXAMEN FINAL · 272 VINOS NUNCA VISTOS

Encuentra 26 de los 37 vinos de alta calidad

0,571
F1 en test
(regla de alcohol: 0,457)

0,703
recall
7 de cada 10 buenos

0,481
precision
casi 5 de cada 10 marcados

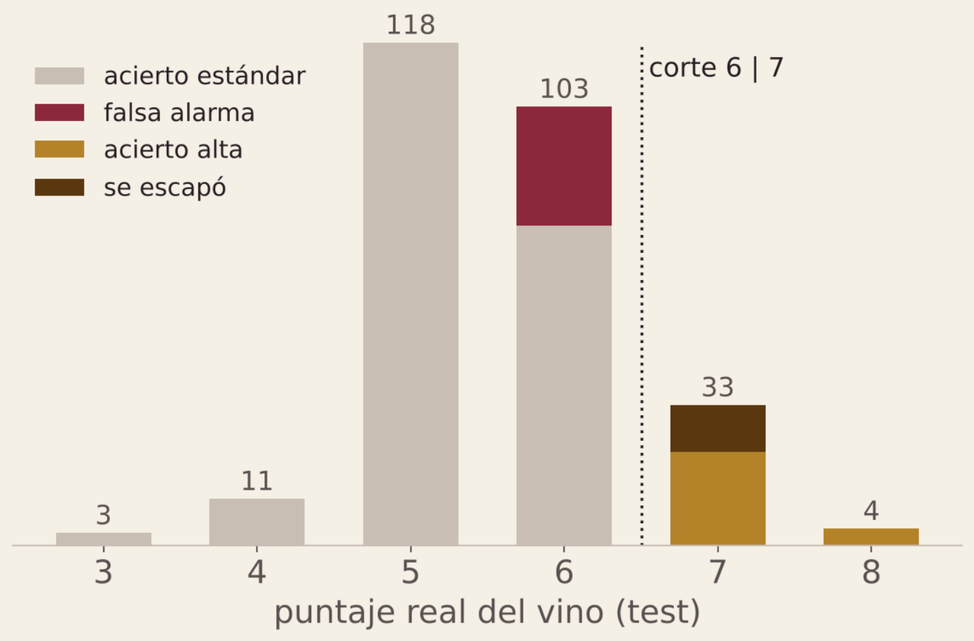
Dentro de lo esperado por la validación cruzada (0,540 ± 0,051): el modelo generaliza.

Matriz de confusión

real \ predicho	estándar	alta
estándar	207	28
alta	11	26

ANÁLISIS DE ERRORES

Se equivoca justo en la frontera entre 6 y 7



28

falsas alarmas: todas son vinos de puntaje 6

11

vinos buenos que se escaparon: todos de puntaje 7

Nunca confundió un vino de 3, 4 o 5 con uno premium, y encontró los 4 vinos de puntaje 8.

PARTE 3 · REGRESIÓN

¿Qué puntaje le darían los catadores?

En vez de «alta o no», ahora predecimos el número: un valor como 5,4 o 6,8. Es el tema de regresión del curso aplicado al vino.

CÓMO SE MIDE UNA REGRESIÓN

Ya no se cuentan aciertos: se mide la distancia

Si el vino tiene 6 y el modelo dice 5,9, no tiene sentido decir que falló. Por eso precision, recall y F1 no sirven aquí.

Métrica	Qué mide	Cómo se lee
MSE	promedio de los errores al cuadrado	menor es mejor
RMSE	raíz del MSE, en puntos de calidad	error típico
MAE	promedio de los errores sin signo	error promedio
R^2	parte de la variación que explica el modelo	0 = media, 1 = perfecto

Un solo error grande

A 4 vinos con errores pequeños les sumamos uno de puntaje 8 predicho como 5:

× 11,7

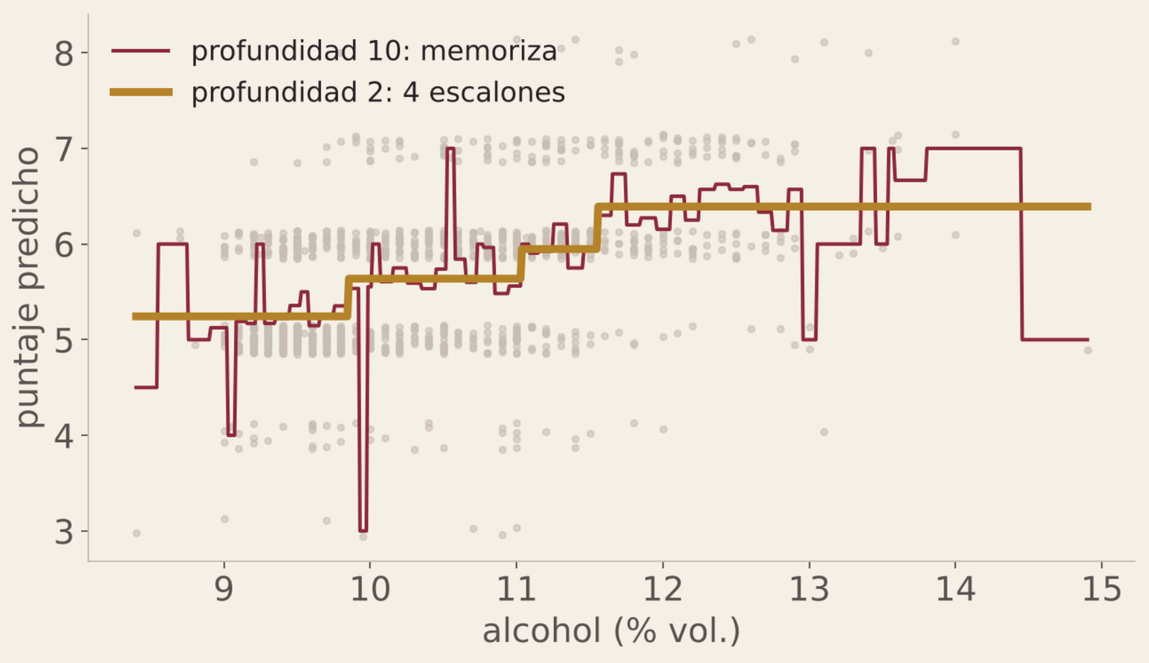
el MSE: castiga mucho los errores grandes

× 2,8

el MAE: todos los errores pesan igual

INTUICIÓN CON UNA VARIABLE

Un árbol de regresión predice con escalones



Como con las bicicletas y la temperatura en clase, usamos solo el alcohol.

Cada hoja predice el promedio de puntaje de sus vinos.

0,518 / 0,542

MSE de validación (10 folds): profundidad 2 / profundidad 10

El árbol profundo se acomoda a vinos concretos y predice peor.

AJUSTE DE LOS REGRESORES

Lo que probamos antes de comparar

Árbol por defecto

Peor que predecir siempre la media: $R^2 = -0{,}26$. Memoriza (error de entrenamiento 0).

Random Forest

Desde unos 100 árboles el error casi no cambia. Fijamos 300, como en la Parte 2.

SVR polinomial

Con grado 1 igual a una recta; con grado 4 el RMSE sube a 1,51. El kernel RBF fue el mejor.

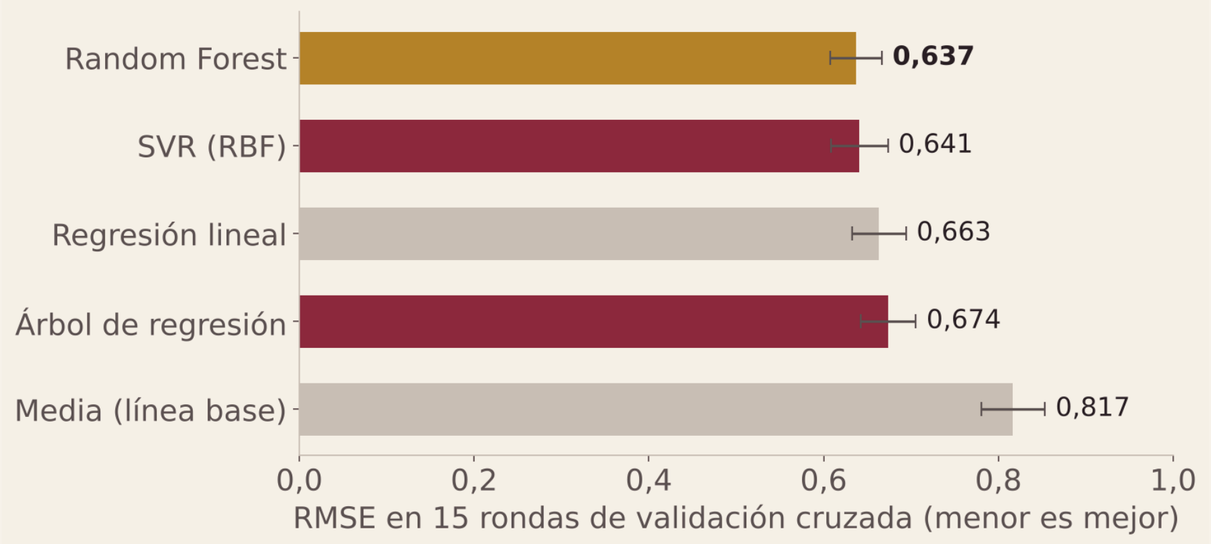
Número de folds

Con más folds el error medio casi no cambia y la dispersión sube. Usamos $K = 5$.

Cada modelo se ajustó con GridSearchCV y KFold de 5 minimizando el RMSE. Líneas base: la media (RMSE 0,817) y la regresión lineal (0,663).

SELECCIÓN

Random Forest gana otra vez, por poco



0,637 ± 0,030

RMSE de Random Forest en 15 rondas (5 × 3)

La SVR queda a 0,004 (0,641). Por la regla fijada antes, en un empate menor a 0,01 decide el MAE: 0,495 contra 0,499.

Los dos superan a la regresión lineal y a la media.

EXAMEN FINAL DEL REGRESOR

Error de medio punto, pero encoge las notas

0,654

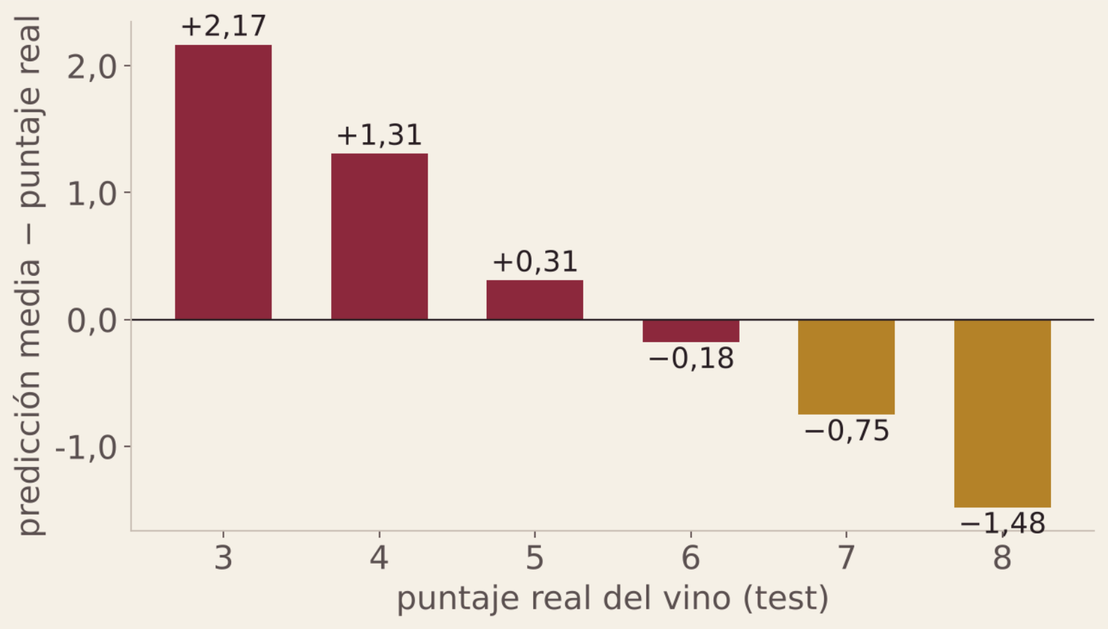
RMSE en test: error típico en puntos

0,502

MAE: error promedio, medio punto

0,404

R^2: explica el 40 % de la variación



A los vinos de 7 y 8 les predice en promedio 6,25 y 6,52: los subestima.

REGRESIÓN FRENTE A CLASIFICACIÓN

Para decidir, gana el clasificador

Para decidir «¿es alta calidad?»	F1	Encuentra	ROC-AUC	PR-AUC
Clasificador Random Forest (umbral 0,5)	0,571	26 de 37	0,877	0,513
Regresor, corte ŷ ≥ 6,5	0,452	14 de 37	0,875	0,520
Regresor, corte ajustado en desarrollo (ŷ ≥ 6,11)	0,516	24 de 37	0,875	0,520

Ordenan igual

ROC-AUC de 0,875 y 0,877: el regresor sí distingue los vinos buenos. Su problema es dónde poner el corte.

Deciden distinto

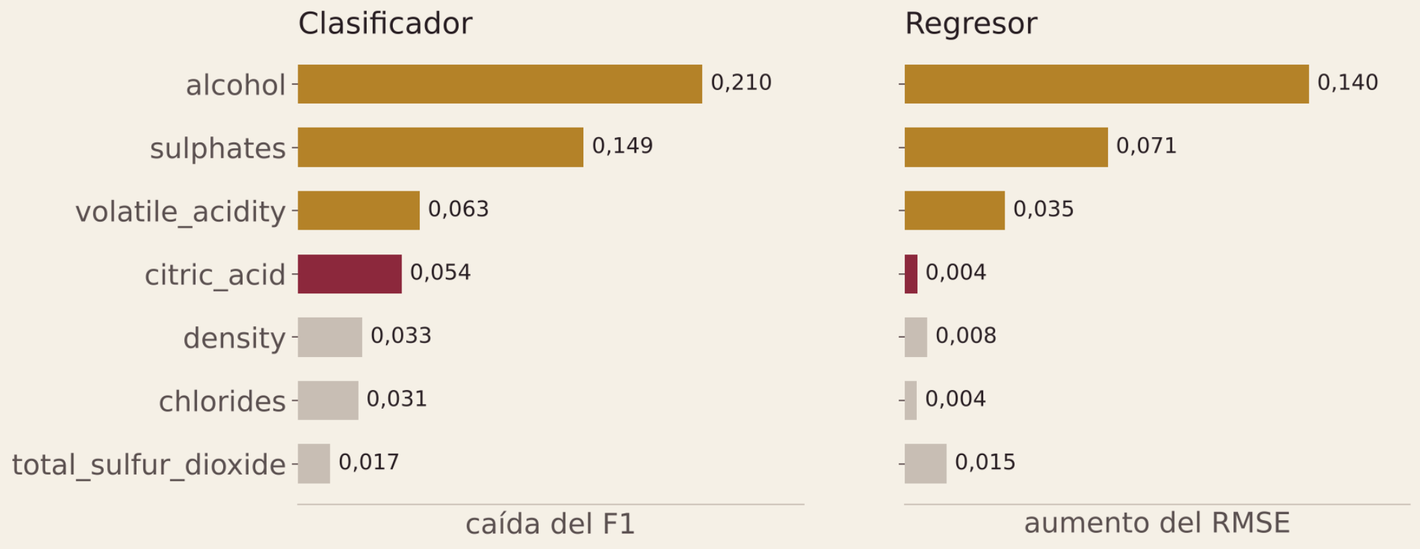
Con el corte 6,5 el regresor se pierde 23 de los 37 vinos buenos. Ajustando el corte mejora, pero no llega a 0,571.

Cuál usar

Para «¿es alta calidad?», el clasificador. El regresor sirve para dar un puntaje estimado y ordenar lotes.

OBJETIVO 2

Alcohol, sulfatos y acidez volátil pesan más en los dos enfoques



Importancia por permutación: desordenamos una variable en el test y medimos cuánto empeora el modelo.

Más alcohol y más sulfatos suben la calidad; más acidez volátil (sabor a vinagre) la baja.

Son las mismas candidatas del análisis exploratorio. Es asociación, no causalidad.

CONCLUSIONES

Sí se puede, como filtro de apoyo al catador

Clasificación

Random Forest: F1 de 0,571 en test. Encuentra 7 de cada 10 vinos premium.

Variables

Alcohol (+), sulfatos (+) y acidez volátil (−) pesan más en todos los análisis.

Regresión

Error típico de 0,65 puntos y R^2 de 0,40, pero subestima los vinos buenos.

Método

Sin duplicados, validación cruzada, pesos de clase y test una sola vez.

Uso propuesto: el clasificador señala qué lotes podrían ser de alta calidad para catarlos primero; el regresor da un puntaje para ordenarlos. Ninguno reemplaza al catador.

LÍMITES Y SIGUIENTES PASOS

Lo que este proyecto no alcanza a resolver

Limitaciones

- Solo 37 vinos buenos en el test: las métricas pueden moverse varios puntos.
- Las notas vienen de catadores y tienen su subjetividad, sobre todo entre 6 y 7.
- Un solo tipo de vino (tinto *Vinho Verde*).
- El laboratorio explica solo el 40 % de la variación del puntaje.

Trabajo futuro

- Fijar el umbral con el costo real de cada error para la bodega.
- Dar más peso a los vinos de los extremos en la regresión.
- Validación cruzada anidada para elegir hiperparámetros con menos optimismo.
- Probar con vino blanco o con datos de otras bodegas.

GRACIAS

¿Preguntas?

Santiago Andres Saavedra Garcia · Manuel Esteban Cardenas Hurtado

Notebook completo: análisis exploratorio, clasificación y regresión